

Homework 1: Information, Probabilités, Entropie

Consignes de rendu : Pour les questions numériques (indiqué par un astérisque), veuillez soumettre un notebook Jupyter qui peut être exécuté de bout en bout sans erreur et qui reproduit tous les résultats demandés dans ce document. Assurez-vous que votre code soit clair, bien commenté et que toutes les dépendances nécessaires soient clairement indiquées. Pour les questions théoriques, vous avez deux options :

- Vous pouvez inclure vos réponses directement dans le notebook Jupyter, en utilisant des cellules de texte Markdown pour une présentation claire et structurée.
- Alternativement, vous pouvez soumettre un fichier PDF séparé contenant vos réponses aux questions théoriques. Dans ce cas, assurez-vous que vos réponses soient bien organisées et correspondent clairement aux numéros des questions.

Dans les deux cas, veillez à ce que vos explications soient claires, concises et rigoureuses. N'hésitez pas à inclure des schémas ou des équations lorsque cela est pertinent pour illustrer vos raisonnements.

Exercice 1 Entropie et compression des données

En 1948, tandis qu'il travaillait aux Laboratoires Bell, l'ingénieur en génie électrique Claude Shannon formalisa mathématiquement la nature statistique de "l'information manquante" dans les signaux des lignes téléphoniques. Pour ce faire, il développa le concept général d'entropie et d'information. Dans ce tutorat, nous allons étudier cette entropie (qui se trouve être la même, à une constante multiplicative près, que celle de Boltzmann) et ses liens avec la compression de données.

Part I — Surprise, incertitude et information

Considérez une variable aléatoire X qui peut prendre une valeur parmi N possibles dans un alphabet χ qui contient L lettres. La probabilité de prendre une valeur $X = x_i \in \chi$ est p_i . Pour cet exercice, considérons par exemple un alphabet de quatre lettres $\chi = \{A, B, C, D\}$ avec les probabilités $p_A = 1/2$, $p_B = 1/4$, $p_C = 1/8$, $p_D = 1/8$.

- Q1.** Nous tirons une valeur $X = x_i$. Plus cette valeur est improbable, plus nous sommes surpris de la voir apparaître. Définissons la "surprise" comme $\log_2 1/p_i$. Le fait que nous soyons surpris est clairement lié au fait que nous ne sommes pas certain du résultat du tirage avant qu'il n'ait lieu. Appelons, avec Shannon, la surprise moyenne "l'incertitude" $H[X]$. Comment s'écrit l'incertitude en général? Que vaut-elle dans notre exemple?
- Q2.** Montrez que l'incertitude $H[X]$ satisfait $0 \leq H[X] \leq \log_2 L$; que la valeur 0 est atteinte si et seulement si une seule lettre a une probabilité non nulle; et que la valeur $\log_2 L$ est atteinte si et seulement si toutes les lettres sont équiprobables.
- Q3.** Une autre approche est la suivante: je mesure une valeur $X = x_i$, mais je la garde secrète en vous laissant le soin de la deviner. Vous ne connaissez que les probabilités p_i , ce qui peut vous donner quand même une idée sur la valeur en question. Plus x_i est probable, plus petite est l'information que je vous donnerais en vous disant ce qu'est vraiment la valeur mesurée x_i . Si l'on définit l'information qu'il vous manque comme $\log_2 1/p_i$, quelle est la valeur moyenne de cette information manquante en général? Que vaut-elle dans notre exemple?

Part II — Entropie de Shannon et questions OUI/NON

Nous voulons maintenant répondre à la question: à quel point est-il difficile de deviner la valeur d'une variable aléatoire?

- Q1.** J'ai tiré au hasard l'une des lettres A,B,C,D avec les probabilités précédentes. Vous avez le droit de poser des questions, du type "Cette lettre est-elle dans l'ensemble $\{x_1, x_2, \dots\}$?", auxquelles je répondrai par oui ou par non. Votre but est de trouver le plus vite possible la lettre tirée. Combien de questions devez vous poser en moyenne avant de découvrir la lettre que j'ai tirée? Comparez ce nombre avec l'entropie de l'alphabet.
- Q2.** Considérons un nouvel alphabet de 2^b lettres équiprobables (avec b entier). Combien des questions est-il nécessaire de poser en moyenne? Comparez avec l'entropie du système.
- Q3.** (Théorème de Shannon (1948)) Considérons enfin un alphabet général avec A lettres x_i , $i = 1 \dots A$ avec probabilités p_i . Comment généraliser la stratégie précédente? Combien des questions devez vous poser en moyenne pour découvrir la lettre tirée? Pour simplifier, on fera l'hypothèse qu'il soit toujours possible de partager les lettres en deux groupes tels que la probabilité de chacun des deux groupes est $1/2$.

Part III — Compression de données

Vous avez un fichier avec N valeurs aléatoires $x_i \in \chi$, l'alphabet χ contenant L lettres. Ce fichier prend une place de $N \log_2 L$ bits dans votre disque dur.

- Q1.** Adoptons la stratégie suivante, en utilisant les questions OUI/NON. On écrit un fichier où, au lieu de garder chaque lettre, on garde, pour chaque lettre, les réponses aux questions de l'exemple précédent avec OUI= 1 et NON=0. Quelle est la taille de ce nouveau fichier? Quel est le facteur de compression (rapport entre la taille du fichier avant et après compression)?
- * **Q2.** Comparez ce résultat avec les performances de votre programme de compression favori (zip, rar ...). Pour cela, utiliser les fichiers ci-joints, qui sont des suites de 10^4 caractères Ascii ¹ tirés au hasard avec les alphabet suivant:
1. *uniform.txt*: caractères tirés au hasard parmi L'ENSEMBLE des 256 possibles.
 2. *half.txt*: caractères tirés au hasard parmi LA MOITIE (soit 128) caractères possibles.
 3. *abcd.txt*: caractères tirés au hasard parmi ABCD.
 4. *abcd2.txt*: caractères tirés au hasard parmi ABCD avec les probabilités de la partie 2.

Part IV — L'entropie de l'anglais

- * **Q1.** Les fréquences des lettres dans l'anglais sont disponibles sur:
http://en.wikipedia.org/wiki/Letter_frequencies. Calculez le rapport de compression de l'anglais (négligez les espaces, majuscules et autres caractères spéciaux.)
- * **Q2.** Comparez vos résultats aux meilleurs compresseurs disponibles:
http://en.wikipedia.org/wiki/Hutter_Prize. D'où vient la différence observée?
- * **Q3.** Estimez (et commentez vos résultats) l'entropie de l'anglais grâce à l'expérience numérique:
<https://www.csfieldguide.org.nz/en/interactives/shannon-experiment/>

Exercice 2 Estimation d'un taux de désintégration (loi de Poisson)

¹On rappelle que les caractères Ascii sont codés sur 8 bits et prennent 256 valeurs possibles, voir <http://fr.wikipedia.org/wiki/ASCII>

On dispose d'un détecteur qui enregistre le nombre de désintégrations d'un échantillon radioactif pendant une durée fixée (par exemple, une minute). Le nombre d'événements X observés dans chaque intervalle suit une loi de Poisson de paramètre inconnu λ^* :

$$\mathbb{P}(X = k) = e^{-\lambda^*} \frac{(\lambda^*)^k}{k!}, \quad k \in \mathbb{N}.$$

Notre objectif est de déterminer ce paramètre λ^* à partir de N mesures indépendantes $X_1, \dots, X_N$. (On prendra $\lambda^* = 3$ pour les simulations).

Q1. (*Fonction génératrice des moments*) On rappelle que la fonction génératrice des moments (MGF) d'une variable aléatoire X est $M_X(t) := \mathbb{E}[e^{tX}]$.

- a) Écrire $M_X(t)$ comme une somme sur k en utilisant une loi de Poisson pour X .
- b) Reconnaître le développement en série d'une fonction usuelle et en déduire que la $M_X(t)$ est donnée par

$$M_X(t) = \mathbb{E}[e^{tX}] = \exp(\lambda^*(e^t - 1)).$$

- c) En déduire la fonction génératrice des cumulants (CGM) $\kappa_X(t) = \log(M_X(t))$ et calculer la moyenne et la variance de X : $\mathbb{E}[X] = K'_X(0)$ et $\text{Var}(X) = K''_X(0)$. Remarque?

* **Q2.** (*Génération de données*) Comment générer numériquement des variables aléatoires X_i suivant la loi de Poisson(λ) ? Écrire une routine qui génère N échantillons pour un λ^* donné (numpy peut faire cela pour vous, mais vous pouvez aussi chercher des information sur la méthode de Knuth).

Q3. (*Estimateur de λ^**) Si l'on a N données $X_i, i = 1 \dots N$, considérons

$$\hat{\lambda}(\{X\}_N) = \frac{1}{N} \sum_{i=1}^N X_i$$

comme un estimateur de λ^* . Quelle est sa moyenne? Sa variance ? Quel va être son erreur typique?

* **Q4.** (*Convergence numérique*) Vérifier numériquement, en changeant N , que $\hat{\lambda}$ converge vers la vraie valeur λ^* . Tracer la distribution empirique de $\hat{\lambda}$ pour différentes valeurs de N . (Pour cela, il faudra, à N fixe, répéter l'expérience un certain nombre de fois)

* **Q5.** (*Théorème Central Limite*) Rappeler le théorème central limite dans ce cadre et préciser la loi limite de $S_N = \sqrt{N}\hat{\lambda}_N$. Que cela signifie-t-il pour la loi de $\hat{\lambda}_N$? Vérifier numériquement que cette loi est bien observée.

Q6. (*Grandes fluctuations*) On veut maintenant calculer la probabilité d'observer une valeur atypique du nombre moyen de désintégrations. Nous allons donc considérer la fonction de grandes deviations:

$$\mathbb{P}(\hat{\lambda}_N \approx s) \asymp e^{-NI(s)},$$

où $I(s)$ est la fonction de taux donnée par le théorème de Cramér : $I(s) = \sup_{t \in \mathbb{R}} \{ts - \kappa_X(t)\}$. Calculer $I(s)$ pour notre problème.

Q7. (*Développement autour de la moyenne*) Développer $I(s)$ au voisinage de $s = \lambda^*$. Montrer que cela redonne l'approximation Gaussienne obtenue par le TCL. Commentez les deviations par rapport à cette loi Gaussienne.

* **Q8.** (*Vérification numérique*) Pour plusieurs valeurs de N , simuler un (grand!) nombre d'expérience: comparer l'histogramme de S_N à la loi Gaussienne issue du TCL. Jusqu'où l'approximation Gaussienne est-elle valable ? Vérifier numériquement la validité de la loi des grandes deviations.